

# 矩阵特征值与特征向量的计算

主讲：王伟

Email: wangw@tongji.edu.cn

同济大学数学科学学院

## 1 前言

# 内容提要

① 前言

② 幂方法

# 内容提要

- 1 前言
- 2 幂方法
- 3 QR方法

# 内容提要

- 1 前言
- 2 幂方法
- 3 QR方法
- 4 Matlab简介: eig函数

# 矩阵特征值问题:

给定 $n$ 阶方阵 $A \in R^{n \times n}$ , 寻找常数 $\lambda \in C$ 和非零向量 $x \in C^n$ , 使得

$$Ax = \lambda x,$$

其中 $C$ 和 $C^n$ 分别表示复数域和 $n$ 维复向量空间。

## §1.1 前言——特征值问题的线性代数解法

### 定义1.1

对于 $n$ 阶方阵 $A$ , 称

$$p(\lambda) = \det(A - \lambda I)$$

为矩阵 $A$ 的**特征多项式**。

## §1.1 前言——特征值问题的线性代数解法

### 定义1.1

对于  $n$  阶方阵  $A$ , 称

$$p(\lambda) = \det(A - \lambda I)$$

为矩阵  $A$  的 **特征多项式**。

### 定义1.2

$p(\lambda)$  是关于  $\lambda$  的  $n$  次多项式, 且  $p$  的零点即为矩阵  $A$  的全部 **特征值**。



## §1.1 前言——特征值问题的线性代数解法

### 定义1.1

对于 $n$ 阶方阵 $A$ , 称

$$p(\lambda) = \det(A - \lambda I)$$

为矩阵 $A$ 的**特征多项式**。

### 定义1.2

$p(\lambda)$ 是关于 $\lambda$ 的 $n$ 次多项式, 且 $p$ 的零点即为矩阵 $A$ 的全部**特征值**。

### 定义1.3

设 $\lambda_i$ 为矩阵 $A$ 的特征值, 由于 $\det(A - \lambda_i I) = 0$ , 故方程 $(A - \lambda_i I)x = 0$ 必有非零解 $x^{(i)}$ , 称 $x^{(i)}$ 为矩阵 $A$ 对应于特征值 $\lambda_i$ 的**特征向量**。

## §1.2 前言——特征值问题的线性代数解法

- 特征多项式与特征方程

$$\det(A - \lambda I) = 0$$

## §1.2 前言——特征值问题的线性代数解法

- 特征多项式与特征方程

$$\det(A - \lambda I) = 0$$

- 线性代数中介绍方法：

第一步 求解特征方程，得到矩阵 $A$ 的所有特征值；

第二步 求解齐次方程 $(A - \lambda_i I)x = 0$ ，得到 $\lambda_i$ 所对应的特征向量。

## §1.2 前言——特征值问题的线性代数解法

- 特征多项式与特征方程

$$\det(A - \lambda I) = 0$$

- 线性代数中介绍方法：

第一步 求解特征方程，得到矩阵 $A$ 的所有特征值；

第二步 求解齐次方程 $(A - \lambda_i I)x = 0$ ，得到 $\lambda_i$ 所对应的特征向量。

- 当矩阵阶数较大时，特征多项式的零点没有简单的解析表达式，只能通过近似计算得到。而高次方程近似求根的稳定性差，求得的近似解会有较大误差！

## §1.2 前言——特征值问题的线性代数解法

### 例1.1

计算矩阵  $\begin{bmatrix} 1 & 0 & 2 \\ 0 & 1 & -1 \\ -1 & 1 & 1 \end{bmatrix}$  的全部特征值。

## §1.2 前言——特征值问题的线性代数解法

### 例1.1

计算矩阵  $\begin{bmatrix} 1 & 0 & 2 \\ 0 & 1 & -1 \\ -1 & 1 & 1 \end{bmatrix}$  的全部特征值。

**解:** 矩阵  $A$  的特征多项式为

$$\begin{aligned} p(\lambda) &= \det(A - \lambda I) = \det \left( \begin{bmatrix} 1-\lambda & 0 & 2 \\ 0 & 1-\lambda & -1 \\ -1 & 1 & 1-\lambda \end{bmatrix} \right) \\ &= (1-\lambda)(\lambda^2 - 2\lambda + 4). \end{aligned}$$

矩阵  $A$  的特征值为  $p(\lambda) = 0$  的解, 即  $\lambda_1 = 1, \lambda_{2,3} = 1 \pm \sqrt{3}i$ 。

## §1.3 前言——特征值问题的基础知识

### 定理1.1

若 $\lambda_i (i = 1, 2, \dots, n)$ 是矩阵 $A$ 的特征值, 则有

(1)  $\sum_{i=1}^n \lambda_i = \text{tr}(A)$ , 其中 $\text{tr}(A) = \sum_{i=1}^n a_{ii}$ 表示矩阵 $A$ 的迹;

(2)  $\prod_{i=1}^n \lambda_i = \det(A)$ 。

## §1.3 前言——特征值问题的基础知识

### 定理1.1

若 $\lambda_i (i = 1, 2, \dots, n)$ 是矩阵 $A$ 的特征值, 则有

(1)  $\sum_{i=1}^n \lambda_i = \text{tr}(A)$ , 其中 $\text{tr}(A) = \sum_{i=1}^n a_{ii}$ 表示矩阵 $A$ 的迹;

(2)  $\prod_{i=1}^n \lambda_i = \det(A)$ 。

### 定义1.4

设 $A, B$ 都是 $n$ 阶矩阵, 若存在可逆矩阵 $P$ , 使得 $P^{-1}AP = B$ , 则称矩阵 $A$ 与矩阵 $B$ 相似。

### 定理1.2

若矩阵 $A$ 与矩阵 $B$ 相似, 则 $A$ 与 $B$ 具有相同的特征值。



## §1.3 前言——特征值问题的基础知识

### 定理1.3 (Gerschgorin圆盘定理)

设  $A = (a_{ij})_{n \times n}$ , 则  $A$  的每一个特征值必属于下述某个圆盘之中

$$|\lambda - a_{ii}| \leq \sum_{j=1, j \neq i}^n |a_{ij}|, \quad i = 1, 2, \dots, n,$$

其中上式表示复平面上以  $a_{ii}$  为中心, 以  $\sum_{j=1, j \neq i}^n |a_{ij}|$  为半径的圆盘。

## §1.3 前言——特征值问题的基础知识

### 定理1.3 (Gerschgorin圆盘定理)

设  $A = (a_{ij})_{n \times n}$ , 则  $A$  的每一个特征值必属于下述某个圆盘之中

$$|\lambda - a_{ii}| \leq \sum_{j=1, j \neq i}^n |a_{ij}|, \quad i = 1, 2, \dots, n,$$

其中上式表示复平面上以  $a_{ii}$  为中心, 以  $\sum_{j=1, j \neq i}^n |a_{ij}|$  为半径的圆盘。

证:

## §1.3 前言——特征值问题的基础知识

### 定理1.3 (Gerschgorin圆盘定理)

设  $A = (a_{ij})_{n \times n}$ , 则  $A$  的每一个特征值必属于下述某个圆盘之中

$$|\lambda - a_{ii}| \leq \sum_{j=1, j \neq i}^n |a_{ij}|, \quad i = 1, 2, \dots, n,$$

其中上式表示复平面上以  $a_{ii}$  为中心, 以  $\sum_{j=1, j \neq i}^n |a_{ij}|$  为半径的圆盘。

证: 设  $\lambda$  是任意特征值,  $x$  是对应的特征向量, 则

$$(\lambda I - A)x = 0.$$

## §1.3 前言——特征值问题的基础知识

### 定理1.3 (Gerschgorin圆盘定理)

设  $A = (a_{ij})_{n \times n}$ , 则  $A$  的每一个特征值必属于下述某个圆盘之中

$$|\lambda - a_{ii}| \leq \sum_{j=1, j \neq i}^n |a_{ij}|, \quad i = 1, 2, \dots, n,$$

其中上式表示复平面上以  $a_{ii}$  为中心, 以  $\sum_{j=1, j \neq i}^n |a_{ij}|$  为半径的圆盘。

证: 设  $\lambda$  是任意特征值,  $x$  是对应的特征向量, 则

$$(\lambda I - A)x = 0.$$

记  $|x_i| = \max_j |x_j| \neq 0$ , 第  $i$  个方程为

$$-\sum_{j \neq i} a_{ij}x_j + (\lambda - a_{ii})x_i = 0,$$

## §1.3 前言——特征值问题的基础知识

### 定理1.3 (Gerschgorin圆盘定理)

设  $A = (a_{ij})_{n \times n}$ , 则  $A$  的每一个特征值必属于下述某个圆盘之中

$$|\lambda - a_{ii}| \leq \sum_{j=1, j \neq i}^n |a_{ij}|, \quad i = 1, 2, \dots, n,$$

其中上式表示复平面上以  $a_{ii}$  为中心, 以  $\sum_{j=1, j \neq i}^n |a_{ij}|$  为半径的圆盘。

证: 记  $|x_i| = \max_j |x_j| \neq 0$ , 第  $i$  个方程为

$$-\sum_{j \neq i} a_{ij} x_j + (\lambda - a_{ii}) x_i = 0,$$

$$|\lambda - a_{ii}| \leq \sum_{j \neq i} |a_{ij}| \left| \frac{x_j}{x_i} \right| \leq \sum_{j \neq i} |a_{ij}|.$$

## §1.3 前言——特征值问题的基础知识

### 例1.2

对于矩阵  $\begin{bmatrix} 4 & 1 & 1 \\ 0 & 2 & 1 \\ -2 & 0 & 9 \end{bmatrix}$ , 圆盘定理中的圆盘为:

$$R_2 = \{\lambda \in \mathbb{C} : |\lambda - 4| \leq 2\} \quad R_1 = \{\lambda \in \mathbb{C} : |\lambda - 2| \leq 1\}$$

$$R_3 = \{\lambda \in \mathbb{C} : |\lambda - 9| \leq 2\}$$


## §1.3 前言——特征值问题的基础知识

### 例1.2

对于矩阵  $\begin{bmatrix} 4 & 1 & 1 \\ 0 & 2 & 1 \\ -2 & 0 & 9 \end{bmatrix}$ , 圆盘定理中的圆盘为:

$$R_2 = \{\lambda \in \mathbb{C} : |\lambda - 4| \leq 2\} \quad R_1 = \{\lambda \in \mathbb{C} : |\lambda - 2| \leq 1\}$$

$$R_3 = \{\lambda \in \mathbb{C} : |\lambda - 9| \leq 2\}$$



注:

$$\lambda_1 = 8.4853$$

$$\lambda_2 = 4.6318$$

$$\lambda_3 = 1.8828$$

## §1.3 前言——特征值问题的基础知识

### 定义1.5

设 $A$ 为 $n$ 阶实对称矩阵, 对于任意非零向量 $x$ , 称 $R(x) = \frac{(Ax, x)}{(x, x)}$ 为关于向量 $x$ 的瑞雷 (Rayleigh) 商, 其中 $(x, y) = \sum_{i=1}^n x_i y_i$ 为 $R^n$ 中两向量 $x, y$ 的内积。



## §1.3 前言——特征值问题的基础知识

### 定义1.5

设 $A$ 为 $n$ 阶实对称矩阵, 对于任意非零向量 $x$ , 称 $R(x) = \frac{(Ax, x)}{(x, x)}$ 为关于向量 $x$ 的瑞雷 (Rayleigh) 商, 其中 $(x, y) = \sum_{i=1}^n x_i y_i$ 为 $R^n$ 中两向量 $x, y$ 的内积。

### 定理1.4

设 $A$ 为 $n$ 阶实对称矩阵,  $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n$ 为其全部特征值, 则

- (1)  $\lambda_n \leq \frac{(Ax, x)}{(x, x)} \leq \lambda_1, \quad \forall x \neq 0 \in R^n;$
- (2)  $\lambda_n = \min_{x \neq 0} \frac{(Ax, x)}{(x, x)} \quad \lambda_1 = \max_{x \neq 0} \frac{(Ax, x)}{(x, x)}.$

## §1.3 前言——特征值问题的基础知识

证: 因为  $A$  是实对称矩阵, 故有完全的特征向量系。设  $x^{(1)}, x^{(2)}, \dots, x^{(n)}$  是  $A$  的规范化正交特征向量组, 即  $(x^{(i)}, x^{(j)}) = \delta_{ij}$ 。任一非零向量  $x$  都

能表示为  $x = \sum_{i=1}^n a_i x^{(i)}$ , 且

$$(x, x) = \left( \sum_{1 \leq i \leq n} \alpha_i x^{(i)}, \sum_{1 \leq i \leq n} \alpha_i x^{(i)} \right) = \sum_{1 \leq i \leq n} \alpha_i^2,$$
$$(Ax, x) = \left( \sum_{1 \leq i \leq n} A \alpha_i x^{(i)}, \sum_{1 \leq i \leq n} \alpha_i x^{(i)} \right) = \sum_{1 \leq i \leq n} \lambda_i \alpha_i^2.$$

故

$$\frac{(Ax, x)}{(x, x)} = \frac{\sum_{i=1}^n \lambda_i \alpha_i^2}{\sum_{i=1}^n \alpha_i^2} \leq \frac{\lambda_1 \sum_{i=1}^n \alpha_i^2}{\sum_{i=1}^n \alpha_i^2} = \lambda_1 \quad x \neq 0.$$

## §1.3 前言——特征值问题的基础知识

故

$$\frac{(Ax, x)}{(x, x)} = \frac{\sum_{i=1}^n \lambda_i \alpha_i^2}{\sum_{i=1}^n \alpha_i^2} \leq \frac{\lambda_1 \sum_{i=1}^n \alpha_i^2}{\sum_{i=1}^n \alpha_i^2} = \lambda_1 \quad x \neq 0.$$

同理可证

$$\frac{(Ax, x)}{(x, x)} \geq \lambda_n. \quad x \neq 0.$$

在瑞雷商中, 分别取  $x = x^{(1)}$  和  $x = x^{(n)}$ , 可达到瑞雷商的最大值  $\lambda_1$  和最小值  $\lambda_n$ , 故

$$\lambda_1 = \max_{x \neq 0} \frac{(Ax, x)}{(x, x)}, \quad \lambda_n = \min_{x \neq 0} \frac{(Ax, x)}{(x, x)}.$$

## §2.1 幂方法——乘幂法

**乘幂法**是一种计算矩阵按模最大特征值的方法, 该方法简单有效并能给出对应的特征向量。

## §2.1 幂方法——乘幂法

**乘幂法**是一种计算矩阵按模最大特征值的方法, 该方法简单有效并能给出对应的特征向量。

乘幂法需对实矩阵 $A$ 做如下**假设**:

- (1) 具有 $n$ 个线性无关的特征向量 $x^{(i)}$ ,  $i = 1, 2, \dots, n$ ;
- (2)  $Ax^{(i)} = \lambda_i x^{(i)}$ , 其中 $\lambda_i$ 是实特征值且满足 $|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|$ .

## §2.1 幂方法——乘幂法

**乘幂法**是一种计算矩阵按模最大特征值的方法, 该方法简单有效并能给出对应的特征向量。

乘幂法需对实矩阵 $A$ 做如下**假设**:

- (1) 具有 $n$ 个线性无关的特征向量 $x^{(i)}$ ,  $i = 1, 2, \dots, n$ ;
- (2)  $Ax^{(i)} = \lambda_i x^{(i)}$ , 其中 $\lambda_i$ 是实特征值且满足 $|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|$ .

**算法描述** (未考虑停止迭代条件)

- 选定初始向量 $v^{(0)} \in R^n$ ;
- 利用关系式 $v^{(k+1)} = Av^{(k)}$ 迭代计算。

## §2.1 幂方法——乘幂法

### 算法2.1 (原始乘幂法)

(1) 给定初始非零向量  $v^{(0)}$  及控制参数  $\varepsilon$ ;

(2)  $v^{(1)} = Av^{(0)}$ ,  $v^{(2)} = Av^{(1)}$ ;

(3)  $\lambda_2 = \frac{1}{N_2} \sum_{j \in M_2} \frac{v_j^{(2)}}{v_j^{(1)}}$ ;

(4) 对  $k = 2, 3, \dots$ , 做

- $v^{(k+1)} = Av^{(k)}$ ;
- $\lambda_{k+1} = \frac{1}{N_{k+1}} \sum_{j \in M_{k+1}} \frac{v_j^{(k+1)}}{v_j^{(k)}}$ ;
- $err_{k+1} = |\lambda_{k+1} - \lambda_k|$ ;
- 当  $err_{k+1} < \varepsilon$  时, 停止迭代;

(5) 返回近似按模最大特征值  $\lambda_{k+1}$  和近似特征向量  $v^{(k+1)}$ .

$M_{k+1}$  为向量  $v^{(k)}$  中非零分量所对应的指标集,

$N_{k+1}$  为向量  $v^{(k)}$  中非零分量的个数

## §2.1 幂方法——乘幂法

### 例2.1

用乘幂法计算矩阵  $A = \begin{bmatrix} 12 & 6 & -6 \\ 6 & 16 & 2 \\ -6 & 2 & 16 \end{bmatrix}$  的按模最大特征值及其对应的特征向量。

**解:**取初始向量  $[1.0, 0.5, -0.5]^T$  和控制参数  $\varepsilon = 1.0 \times 10^{-4}$ 。利用迭代关系式  $v^{(k+1)} = Av^{(k)}$  进行计算



## §2.1 幂方法——乘幂法

### 例2.1

用乘幂法计算矩阵  $A = \begin{bmatrix} 12 & 6 & -6 \\ 6 & 16 & 2 \\ -6 & 2 & 16 \end{bmatrix}$  的按模最大特征值及其对应的特征向量。

k	$v^{(k)}$	$\lambda_k$	$err_k$
0	[1.0, 0.5, -0.5]	—	—
1	[18, 13, -13]	23.3333	—
2	[372, 290, -290]	21.7607	1.5726
3	[7944, 6292, -6292]	21.5826	0.1780
4	[170832, 135752, -135752]	21.5517	0.0309
5	[3679008, 2925520, -2925520]	21.5456	0.0061
6	[79254336, 63031328, -63031328]	21.5443	0.0013
7	[1707427968, 135796408, -1357964608]	21.5441	0.0003
8	[36784710912, 2925607232, -2925607232]	21.5440	<0.0001

## §2.1 幂方法——乘幂法

### 例2.1

用乘幂法计算矩阵  $A = \begin{bmatrix} 12 & 6 & -6 \\ 6 & 16 & 2 \\ -6 & 2 & 16 \end{bmatrix}$  的按模最大特征值及其对应的特征向量。

**解:**取按模最大特征值  $\lambda_1 \approx 21.5440$ , 对应的特征向量为

$$\mathbf{x}^{(1)} \approx [36784710912, 2925607232, -2925607232]^T.$$

**注:** 特征向量  $\mathbf{x}^{(1)}$  的分量随着  $k$  的增大而不断增大!

## §2.2 幂方法——算法分析

- 取初始向量  $v^{(0)} \in R^n$ ,  $x^{(1)}, x^{(2)}, \dots, x^{(n)}$  线性无关, 故

$$v^{(0)} = \sum_{i=1}^n \alpha_i x^{(i)} = \alpha_1 x^{(1)} + \alpha_2 x^{(2)} + \dots + \alpha_n x^{(n)}.$$

## §2.2 幂方法——算法分析

- 取初始向量  $v^{(0)} \in R^n$ ,  $x^{(1)}, x^{(2)}, \dots, x^{(n)}$  线性无关, 故

$$v^{(0)} = \sum_{i=1}^n \alpha_i x^{(i)} = \alpha_1 x^{(1)} + \alpha_2 x^{(2)} + \dots + \alpha_n x^{(n)}.$$

- 利用  $v^{(k+1)} = Av^{(k)}$  计算得向量序列  $\{v^{(k)}\}$ .

## §2.2 幂方法——算法分析

- 取初始向量  $v^{(0)} \in R^n$ ,  $x^{(1)}, x^{(2)}, \dots, x^{(n)}$  线性无关, 故

$$v^{(0)} = \sum_{i=1}^n \alpha_i x^{(i)} = \alpha_1 x^{(1)} + \alpha_2 x^{(2)} + \dots + \alpha_n x^{(n)}.$$

- 利用  $v^{(k+1)} = Av^{(k)}$  计算得向量序列  $\{v^{(k)}\}$ .
- 对  $\{v^{(k)}\}_{k=0}^{\infty}$ , 因为  $Ax^{(i)} = \lambda_i x^{(i)}$ , 所以

$$\begin{aligned} v^{(1)} &= Av^{(0)} = \lambda_1 \alpha_1 x^{(1)} + \lambda_2 \alpha_2 x^{(2)} + \dots + \lambda_n \alpha_n x^{(n)}, \\ v^{(2)} &= Av^{(1)} = \lambda_1^2 \alpha_1 x^{(1)} + \lambda_2^2 \alpha_2 x^{(2)} + \dots + \lambda_n^2 \alpha_n x^{(n)}. \end{aligned}$$

## §2.2 幂方法——算法分析

- 取初始向量  $v^{(0)} \in R^n$ ,  $x^{(1)}, x^{(2)}, \dots, x^{(n)}$  线性无关, 故

$$v^{(0)} = \sum_{i=1}^n \alpha_i x^{(i)} = \alpha_1 x^{(1)} + \alpha_2 x^{(2)} + \dots + \alpha_n x^{(n)}.$$

- 利用  $v^{(k+1)} = Av^{(k)}$  计算得向量序列  $\{v^{(k)}\}$ .
- 对  $\{v^{(k)}\}_{k=0}^\infty$ , 因为  $Ax^{(i)} = \lambda_i x^{(i)}$ , 所以

$$\begin{aligned} v^{(1)} &= Av^{(0)} = \lambda_1 \alpha_1 x^{(1)} + \lambda_2 \alpha_2 x^{(2)} + \dots + \lambda_n \alpha_n x^{(n)}, \\ v^{(2)} &= Av^{(1)} = \lambda_1^2 \alpha_1 x^{(1)} + \lambda_2^2 \alpha_2 x^{(2)} + \dots + \lambda_n^2 \alpha_n x^{(n)}. \end{aligned}$$

- 归纳法得

$$\begin{aligned} v^{(k)} &= Av^{(k-1)} = \lambda_1^k \alpha_1 x^{(1)} + \lambda_2^k \alpha_2 x^{(2)} + \dots + \lambda_n^k \alpha_n x^{(n)} \\ &= \lambda_1^k \left( \alpha_1 x^{(1)} + \left( \frac{\lambda_2}{\lambda_1} \right)^k \alpha_2 x^{(2)} + \dots + \left( \frac{\lambda_n}{\lambda_1} \right)^k \alpha_n x^{(n)} \right). \end{aligned}$$

## §2.2 幂方法——算法分析

- 由  $\left| \frac{\lambda_i}{\lambda_1} \right| < 1$ , 当  $k$  充分大时, 所以

$$v^{(k)} \approx \lambda_1^k \alpha_1 x^{(1)}.$$

## §2.2 幂方法——算法分析

- 由  $\left| \frac{\lambda_i}{\lambda_1} \right| < 1$ , 当  $k$  充分大时, 所以

$$v^{(k)} \approx \lambda_1^k \alpha_1 x^{(1)}.$$

- 于是

$$v^{(k+1)} \approx \lambda_1^{k+1} \alpha_1 x^{(1)} \approx \lambda_1 v^{(k)}.$$



## §2.2 幂方法——算法分析

- 由  $\left| \frac{\lambda_i}{\lambda_1} \right| < 1$ , 当  $k$  充分大时, 所以

$$v^{(k)} \approx \lambda_1^k \alpha_1 x^{(1)}.$$

- 于是

$$v^{(k+1)} \approx \lambda_1^{k+1} \alpha_1 x^{(1)} \approx \lambda_1 v^{(k)}.$$

- 注意到

$$v^{(k+1)} = Av^{(k)},$$

## §2.2 幂方法——算法分析

- 由  $\left| \frac{\lambda_i}{\lambda_1} \right| < 1$ , 当  $k$  充分大时, 所以

$$v^{(k)} \approx \lambda_1^k \alpha_1 x^{(1)}.$$

- 于是

$$v^{(k+1)} \approx \lambda_1^{k+1} \alpha_1 x^{(1)} \approx \lambda_1 v^{(k)}.$$

- 注意到

$$v^{(k+1)} = Av^{(k)},$$

- 则有

$$Av^{(k)} \approx \lambda_1 v^{(k)}.$$

## §2.2 幂方法——算法分析

- 由  $\left| \frac{\lambda_i}{\lambda_1} \right| < 1$ , 当  $k$  充分大时, 所以

$$v^{(k)} \approx \lambda_1^k \alpha_1 x^{(1)}.$$

- 于是

$$v^{(k+1)} \approx \lambda_1^{k+1} \alpha_1 x^{(1)} \approx \lambda_1 v^{(k)}.$$

- 注意到

$$v^{(k+1)} = Av^{(k)},$$

- 则有

$$Av^{(k)} \approx \lambda_1 v^{(k)}.$$

- 这表明  $v^{(k)}$  可以近似地作为矩阵  $A$  按模最大特征值  $\lambda_1$  所对应的特征向量。

## §2.2 幂方法——算法分析

- 由  $\left| \frac{\lambda_i}{\lambda_1} \right| < 1$ , 当  $k$  充分大时, 所以

$$v^{(k)} \approx \lambda_1^k \alpha_1 x^{(1)}.$$

- 于是

$$v^{(k+1)} \approx \lambda_1^{k+1} \alpha_1 x^{(1)} \approx \lambda_1 v^{(k)}.$$

- 注意到

$$v^{(k+1)} = Av^{(k)},$$

- 则有

$$Av^{(k)} \approx \lambda_1 v^{(k)}.$$

- 这表明  $v^{(k)}$  可以近似地作为矩阵  $A$  按模最大特征值  $\lambda_1$  所对应的特征向量。若将向量  $v^{(k)}$  的第  $j$  个分量记为  $v_j^{(k)}$ , 则

$$\lambda_1 \approx \frac{v_j^{(k+1)}}{v_j^{(k)}} \quad \text{或} \quad \lambda_1 \approx \frac{1}{n} \sum_{j=1}^n \frac{v_j^{(k+1)}}{v_j^{(k)}}, \quad v_j^{(k)} \neq 0.$$

## §2.2 幂方法——算法分析

### “上溢”和“下溢”现象

从上例可以看出, 随着迭代步数 $k$ 的增加, 向量 $v^{(k)}$ 的分量逐渐增大。事实上, 当 $|\lambda_1| > 1$ 或 $|\lambda_1| < 1$ 时, 向量序列 $\{v^{(k)}\}$ 中, 各个不为零的分量将会随着 $k$ 的增大, 而或无限增大或趋于零。

### 规范化

规范化的方法为用 $v^{(k)}$ 的按模最大分量, 记为 $\max[v^{(k)}]$ , 去除所有分量, 得到向量 $u^{(k)} = \frac{v^{(k)}}{\max[v^{(k)}]}$ . 利用规范化的方法可将向量 $u^{(k)}$ 的各个分量控制在 $[-1, 1]$ 中.

## §2.2 幂方法——算法分析

### “上溢”和“下溢”现象

从上例可以看出, 随着迭代步数 $k$ 的增加, 向量 $v^{(k)}$ 的分量逐渐增大。事实上, 当 $|\lambda_1| > 1$ 或 $|\lambda_1| < 1$ 时, 向量序列 $\{v^{(k)}\}$ 中, 各个不为零的分量将会随着 $k$ 的增大, 而或无限增大或趋于零。

### 规范化

规范化的方法为用 $v^{(k)}$ 的按模最大分量, 记为 $\max[v^{(k)}]$ , 去除所有分量, 得到向量 $u^{(k)} = \frac{v^{(k)}}{\max[v^{(k)}]}$ . 利用规范化的方法可将向量 $u^{(k)}$ 的各个分量控制在 $[-1, 1]$ 中.

例如, 若 $v^{(k)} = [-2, 3, -5, 1]^T$ , 则 $\max[v^{(k)}] = -5$ ,  
 $u^{(k)} = [0.4, -0.6, 1, -0.2]^T$ .

## §2.3 幂方法——改进乘幂法

### 算法2.2 (改进乘幂法)

- (1) 给定初始非零向量  $v^{(0)}$  及控制参数  $\varepsilon$ ;
- (2)  $\lambda_0$  为向量  $v^{(0)}$  的按模最大分量;
- (3)  $u^{(0)} = v^{(0)} / \lambda_0$ ;
- (4) 对  $k = 1, 2, \dots$ , 做
  - $v^{(k+1)} = Au^{(k)}$ ;
  - $\lambda_{k+1}$  为向量  $v^{(k+1)}$  的按模最大分量;
  - $u^{(k+1)} = v^{(k+1)} / \lambda_{k+1}$ ;
  - $err_k = |\lambda_{k+1} - \lambda_k|$ ;
  - 当  $err_k < \varepsilon$  时, 停止迭代;
- (5) 返回近似按模最大特征值  $\lambda_{k+1}$  和近似特征向量  $u^{(k+1)}$ 。

## §2.3 幂方法——改进乘幂法

### 例2.2

用改进乘幂法计算例2.1中矩阵 $A$ 的按模最大特征值及其对应的特征向量。

**解:**取初始向量 $v^{(0)} = [1.0, 0.5, -0.5]^T$ 和控制参数 $\varepsilon = 1.0 \times 10^{-4}$ .  
则 $\lambda_0 = 1$ 和 $u^{(0)} = v^{(0)}$ .



## §2.3 幂方法——改进乘幂法

### 例2.2

用改进乘幂法计算例2.1中矩阵 $A$ 的按模最大特征值及其对应的特征向量。

$k$	$v^{(k)}$	$\lambda_k$	$u^{(k)}$
0	[1.0, 0.5, -0.5]	1.0000	[1.0000, 0.5000, -0.5000]
1	[18, 13, -13]	18.0000	[1.0000, 0.7222, -0.7222]
2	[20.6667, 16.1111, -16.1111]	20.6667	[1.0000, 0.7796, -0.7796]
3	[21.3548, 16.9140, -16.9140]	21.3548	[1.0000, 0.7920, -0.7920]
4	[21.5045, 17.0886, -17.0886]	21.5045	[1.0000, 0.7947, -0.7947]
5	[21.5358, 17.1251, -17.1251]	21.5358	[1.0000, 0.7952, -0.7952]
6	[21.5423, 17.1327, -17.1327]	21.5423	[1.0000, 0.7953, -0.7953]
7	[21.5437, 17.1343, -17.1343]	21.5437	[1.0000, 0.7953, -0.7953]
8	[21.5439, 17.1346, -17.1346]	21.5439	[1.0000, 0.7953, -0.7953]
9	[21.5440, 17.1347, -17.1347]	21.5440	[1.0000, 0.7953, -0.7953]

## §2.3 幂方法——改进乘幂法

### 例2.2

用改进乘幂法计算例2.1中矩阵 $A$ 的按模最大特征值及其对应的特征向量。

**解:**当 $k = 9$ 时 $err_9 < \varepsilon$ , 迭代停止。

矩阵 $A$ 的按模最大特征值 $\lambda_1 \approx 21.5440$ ,

对应的特征向量 $x^{(1)} \approx [1.0000, 0.7953, -0.7953]^T$ .

## §2.4 幂方法——算法分析

- 取初始向量  $v^{(0)}$ , 由  $u^{(k)} = \frac{v^{(k)}}{\max[v^{(k)}]}, v^{(k+1)} = Au^{(k)}$   
得  $\{u^{(k)}\}_{k=0}^{\infty}$  和  $\{v^{(k)}\}_{k=0}^{\infty}$ .

## §2.4 幂方法——算法分析

- 取初始向量  $v^{(0)}$ , 由  $u^{(k)} = \frac{v^{(k)}}{\max[v^{(k)}]}, v^{(k+1)} = Au^{(k)}$   
得  $\{u^{(k)}\}_{k=0}^{\infty}$  和  $\{v^{(k)}\}_{k=0}^{\infty}$ .

$$v^{(0)} = \alpha_1 x^{(1)} + \alpha_2 x^{(2)} + \cdots + \alpha_n x^{(n)},$$

## §2.4 幂方法——算法分析

- 取初始向量  $v^{(0)}$ , 由  $u^{(k)} = \frac{v^{(k)}}{\max[v^{(k)}]}, v^{(k+1)} = Au^{(k)}$   
得  $\{u^{(k)}\}_{k=0}^{\infty}$  和  $\{v^{(k)}\}_{k=0}^{\infty}$ .

$$u^{(0)} = \frac{v^{(0)}}{\max[v^{(0)}]} = \frac{\alpha_1 x^{(1)} + \alpha_2 x^{(2)} + \cdots + \alpha_n x^{(n)}}{\max[\alpha_1 x^{(1)} + \alpha_2 x^{(2)} + \cdots + \alpha_n x^{(n)}]},$$

$$v^{(1)} = Au^{(0)} = \frac{\lambda_1 \alpha_1 x^{(1)} + \lambda_2 \alpha_2 x^{(2)} + \cdots + \lambda_n \alpha_n x^{(n)}}{\max[\alpha_1 x^{(1)} + \alpha_2 x^{(2)} + \cdots + \alpha_n x^{(n)}]}.$$

## §2.4 幂方法——算法分析

- 取初始向量  $v^{(0)}$ , 由  $u^{(k)} = \frac{v^{(k)}}{\max[v^{(k)}]}, v^{(k+1)} = Au^{(k)}$   
得  $\{u^{(k)}\}_{k=0}^{\infty}$  和  $\{v^{(k)}\}_{k=0}^{\infty}$ .

$$u^{(0)} = \frac{v^{(0)}}{\max[v^{(0)}]} = \frac{\alpha_1 x^{(1)} + \alpha_2 x^{(2)} + \cdots + \alpha_n x^{(n)}}{\max[\alpha_1 x^{(1)} + \alpha_2 x^{(2)} + \cdots + \alpha_n x^{(n)}]},$$

$$v^{(1)} = Au^{(0)} = \frac{\lambda_1 \alpha_1 x^{(1)} + \lambda_2 \alpha_2 x^{(2)} + \cdots + \lambda_n \alpha_n x^{(n)}}{\max[\alpha_1 x^{(1)} + \alpha_2 x^{(2)} + \cdots + \alpha_n x^{(n)}]}.$$

- 则

$$u^{(k)} = \frac{\lambda_1^k \alpha_1 x^{(1)} + \lambda_2^k \alpha_2 x^{(2)} + \cdots + \lambda_n^k \alpha_n x^{(n)}}{\max[\lambda_1^k \alpha_1 x^{(1)} + \lambda_2^k \alpha_2 x^{(2)} + \cdots + \lambda_n^k \alpha_n x^{(n)}]},$$

$$v^{(k+1)} = Au^{(k)} = \frac{\lambda_1^{k+1} \alpha_1 x^{(1)} + \lambda_2^{k+1} \alpha_2 x^{(2)} + \cdots + \lambda_n^{k+1} \alpha_n x^{(n)}}{\max[\lambda_1^k \alpha_1 x^{(1)} + \lambda_2^k \alpha_2 x^{(2)} + \cdots + \lambda_n^k \alpha_n x^{(n)}]}.$$

## §2.4 幂方法——算法分析

所以,

$$u^{(k)} = \frac{\alpha_1 x^{(1)} + \left(\frac{\lambda_2}{\lambda_1}\right)^k \alpha_2 x^{(2)} + \cdots + \left(\frac{\lambda_n}{\lambda_1}\right)^k \alpha_n x^{(n)}}{\max[\alpha_1 x^{(1)} + \left(\frac{\lambda_2}{\lambda_1}\right)^k \alpha_2 x^{(2)} + \cdots + \left(\frac{\lambda_n}{\lambda_1}\right)^k \alpha_n x^{(n)}]},$$
$$\max[v^{(k+1)}] = \lambda_1 \frac{\max[\alpha_1 x^{(1)} + \left(\frac{\lambda_2}{\lambda_1}\right)^{k+1} \alpha_2 x^{(2)} + \cdots + \left(\frac{\lambda_n}{\lambda_1}\right)^{k+1} \alpha_n x^{(n)}]}{\max[\alpha_1 x^{(1)} + \left(\frac{\lambda_2}{\lambda_1}\right)^k \alpha_2 x^{(2)} + \cdots + \left(\frac{\lambda_n}{\lambda_1}\right)^k \alpha_n x^{(n)}]}.$$

## §2.4 幂方法——算法分析

所以,

$$u^{(k)} = \frac{\alpha_1 x^{(1)} + \left(\frac{\lambda_2}{\lambda_1}\right)^k \alpha_2 x^{(2)} + \cdots + \left(\frac{\lambda_n}{\lambda_1}\right)^k \alpha_n x^{(n)}}{\max[\alpha_1 x^{(1)} + \left(\frac{\lambda_2}{\lambda_1}\right)^k \alpha_2 x^{(2)} + \cdots + \left(\frac{\lambda_n}{\lambda_1}\right)^k \alpha_n x^{(n)}]},$$
$$\max[v^{(k+1)}] = \lambda_1 \frac{\max[\alpha_1 x^{(1)} + \left(\frac{\lambda_2}{\lambda_1}\right)^{k+1} \alpha_2 x^{(2)} + \cdots + \left(\frac{\lambda_n}{\lambda_1}\right)^{k+1} \alpha_n x^{(n)}]}{\max[\alpha_1 x^{(1)} + \left(\frac{\lambda_2}{\lambda_1}\right)^k \alpha_2 x^{(2)} + \cdots + \left(\frac{\lambda_n}{\lambda_1}\right)^k \alpha_n x^{(n)}]}.$$

由  $\left|\frac{\lambda_i}{\lambda_1}\right| < 1$  ( $i = 2, 3, \cdots, n$ ), 当  $k$  充分大时,

$$u^{(k+1)} \approx u^{(k)} \approx \frac{x^{(1)}}{\max[x^{(1)}]}, \quad \max[v^{(k+1)}] \approx \lambda_1.$$



## §2.4 幂方法——算法分析

从而

$$u^{(k+1)} = \frac{v^{(k+1)}}{\max[v^{(k+1)}]} \approx \frac{Au^{(k)}}{\lambda_1} \approx \frac{Au^{(k+1)}}{\lambda_1}.$$

则 $\max[v^{(k+1)}]$ 可作为按模最大特征值 $\lambda_1$ 的近似,  $u^{(k+1)}$ 可作为对应的近似特征向量。

## §2.5 幂方法——源程序

```
function [t,y] = eigIPower(a,xinit,ep)
    v0 = xinit;
    [tv,ti] = max(abs(v0));
    lam0 = v0(ti);
    u0 = v0/lam0;    flag = 0;
    while (flag==0)
        v1 = a*u0;
        [tv,ti] = max(abs(v1));
        lam1 = v1(ti);
        u0 = v1/lam1;
        err = abs(lam0-lam1);
        if (err<=ep)
            flag = 1;
        end
        lam0 = lam1;
    end
    t = lam1;    y = u0;
```

### 例2.3

用改进的乘幂法求下面矩阵的按模最大的特征值和对应的特征向量, 精度为 $10^{-4}$ .

$$A = \begin{bmatrix} 3 & 2 \\ 4 & 5 \end{bmatrix}$$

### 例2.3

用改进的乘幂法求下面矩阵的按模最大的特征值和对应的特征向量, 精度为 $10^{-4}$ .

$$A = \begin{bmatrix} 3 & 2 \\ 4 & 5 \end{bmatrix}$$

$$\begin{aligned} v_0 &= \begin{bmatrix} 1 \\ 1 \end{bmatrix}, & u_0 &= \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \\ v_1 &= \begin{bmatrix} 5 \\ 9 \end{bmatrix}, & \|v_1\|_\infty &= 9 \end{aligned}$$

### 例2.3

用改进的乘幂法求下面矩阵的按模最大的特征值和对应的特征向量, 精度为 $10^{-4}$ .

$$A = \begin{bmatrix} 3 & 2 \\ 4 & 5 \end{bmatrix}$$

$$\begin{aligned} v_1 &= \begin{bmatrix} 5 \\ 9 \end{bmatrix}, u_1 = \begin{bmatrix} 0.5556 \\ 1.0000 \end{bmatrix}, \\ v_2 &= \begin{bmatrix} 3.6667 \\ 7.2222 \end{bmatrix}, \|v_2\|_{\infty} = 7.2222 \end{aligned}$$

### 例2.3

用改进的乘幂法求下面矩阵的按模最大的特征值和对应的特征向量, 精度为 $10^{-4}$ .

$$A = \begin{bmatrix} 3 & 2 \\ 4 & 5 \end{bmatrix}$$

$$v_2 = \begin{bmatrix} 3.6667 \\ 7.2222 \end{bmatrix}, u_2 = \begin{bmatrix} 0.5077 \\ 1.0000 \end{bmatrix},$$
$$v_3 = \begin{bmatrix} 3.5231 \\ 7.0308 \end{bmatrix}, \|v_3\|_{\infty} = 7.0308$$

## 例2.3

用改进的乘幂法求下面矩阵的按模最大的特征值和对应的特征向量, 精度为 $10^{-4}$ .

$$A = \begin{bmatrix} 3 & 2 \\ 4 & 5 \end{bmatrix}$$

$$\begin{aligned} v_3 &= \begin{bmatrix} 3.5231 \\ 7.0308 \end{bmatrix}, u_3 = \begin{bmatrix} 0.5011 \\ 1.0000 \end{bmatrix}, \\ v_4 &= \begin{bmatrix} 3.5033 \\ 7.0006 \end{bmatrix}, \|v_4\|_\infty = 7.0006 \end{aligned}$$

## 例2.3

用改进的乘幂法求下面矩阵的按模最大的特征值和对应的特征向量, 精度为 $10^{-4}$ .

$$A = \begin{bmatrix} 3 & 2 \\ 4 & 5 \end{bmatrix}$$

$$v_4 = \begin{bmatrix} 3.5033 \\ 7.0006 \end{bmatrix}, u_4 = \begin{bmatrix} 0.5000 \\ 1.0000 \end{bmatrix},$$
$$v_5 = \begin{bmatrix} 3.5001 \\ 7.0000 \end{bmatrix}, \|v_5\|_{\infty} = 7.0000$$



### 例2.3

用改进的乘幂法求下面矩阵的按模最大的特征值和对应的特征向量, 精度为 $10^{-4}$ .

$$A = \begin{bmatrix} 3 & 2 \\ 4 & 5 \end{bmatrix}$$

$$v_5 = \begin{bmatrix} 3.5001 \\ 7.0000 \end{bmatrix}, u_5 = \begin{bmatrix} 0.5000 \\ 1.0000 \end{bmatrix},$$
$$v_6 = \begin{bmatrix} 3.5001 \\ 7.0000 \end{bmatrix}, \|v_6\|_\infty = 7.0000$$

## §2.6 幂方法——反幂法

**反幂法** 可用来计算非奇异矩阵的按模最小特征值及其对应的特征向量。

## §2.6 幂方法——反幂法

**反幂法** 可用来计算非奇异矩阵的按模最小特征值及其对应的特征向量。

反幂法需对实矩阵  $A$  作如下假设:

- (1) 具有  $n$  个线性无关的特征向量  $x^{(i)}$ ;
- (2)  $Ax^{(i)} = \lambda_i x^{(i)}$ , 其中  $\lambda_i$  是实特征值且满足  $|\lambda_1| \geq |\lambda_2| \geq \cdots > |\lambda_n| > 0$ .

## §2.6 幂方法——反幂法

**反幂法**可用来计算非奇异矩阵的按模最小特征值及其对应的特征向量。

反幂法需对实矩阵 $A$ 作如下假设:

- (1) 具有 $n$ 个线性无关的特征向量 $x^{(i)}$ ;
- (2)  $Ax^{(i)} = \lambda_i x^{(i)}$ , 其中 $\lambda_i$ 是实特征值且满足 $|\lambda_1| \geq |\lambda_2| \geq \cdots > |\lambda_n| > 0$ .

因为 $Ax = \lambda x \Rightarrow A^{-1}x = \lambda^{-1}x$

## §2.6 幂方法——反幂法

**反幂法**可用来计算非奇异矩阵的按模最小特征值及其对应的特征向量。

反幂法需对实矩阵 $A$ 作如下假设:

- (1) 具有 $n$ 个线性无关的特征向量 $x^{(i)}$ ;
- (2)  $Ax^{(i)} = \lambda_i x^{(i)}$ , 其中 $\lambda_i$ 是实特征值且满足 $|\lambda_1| \geq |\lambda_2| \geq \cdots > |\lambda_n| > 0$ .

因为 $Ax = \lambda x \Rightarrow A^{-1}x = \lambda^{-1}x$

所以 $A^{-1}$ 的特征值满足

$$|\lambda_1^{-1}| \leq |\lambda_2^{-1}| \leq \cdots < |\lambda_n^{-1}|.$$

## §2.6 幂方法——反幂法

**反幂法**可用来计算非奇异矩阵的按模最小特征值及其对应的特征向量。

反幂法需对实矩阵 $A$ 作如下假设:

- (1) 具有 $n$ 个线性无关的特征向量 $x^{(i)}$ ;
- (2)  $Ax^{(i)} = \lambda_i x^{(i)}$ , 其中 $\lambda_i$ 是实特征值且满足 $|\lambda_1| \geq |\lambda_2| \geq \cdots > |\lambda_n| > 0$ .

因为 $Ax = \lambda x \Rightarrow A^{-1}x = \lambda^{-1}x$

所以 $A^{-1}$ 的特征值满足

$$|\lambda_1^{-1}| \leq |\lambda_2^{-1}| \leq \cdots < |\lambda_n^{-1}|.$$

- 乘幂法求得矩阵 $A^{-1}$ 的按模最大特征值 $\mu_n$ 及特征向量 $x^{(n)}$ 。
- 得矩阵 $A$ 的按模最小特征值 $\lambda_n = \mu_n^{-1}$ 及特征向量 $x^{(n)}$ 。

## §2.6 幂方法——反幂法

### 算法2.3 (反幂法)

- (1) 给定初始非零向量  $v^{(0)}$  及控制参数  $\varepsilon$ ;
- (2)  $\lambda_0$  为向量  $v^{(0)}$  的按模最大分量;
- (3)  $u^{(0)} = v^{(0)} / \lambda_0$ ;
- (4) 对  $k = 1, 2, \dots$ , 做
  - $v^{(k+1)} = A^{-1} u^{(k)}$ ;
  - $\lambda_{k+1}$  为向量  $v^{(k+1)}$  的按模最大分量;
  - $u^{(k+1)} = v^{(k+1)} / \lambda_{k+1}$ ;
  - $err_k = |\lambda_{k+1}^{-1} - \lambda_k^{-1}|$ ;
  - 当  $err_k < \varepsilon$  时, 停止迭代;
- (5) 返回近似按模最小特征值  $\lambda_{k+1}^{-1}$  和近似特征向量  $u^{(k+1)}$ .

## §2.6 幂方法——反幂法

### 算法2.3 (反幂法)

- (1) 给定初始非零向量  $v^{(0)}$  及控制参数  $\varepsilon$ ;
- (2)  $\lambda_0$  为向量  $v^{(0)}$  的按模最大分量;
- (3)  $u^{(0)} = v^{(0)} / \lambda_0$ ;
- (4) 对  $k = 1, 2, \dots$ , 做
  - $Av^{(k+1)} = u^{(k)}$ ;
  - $\lambda_{k+1}$  为向量  $v^{(k+1)}$  的按模最大分量;
  - $u^{(k+1)} = v^{(k+1)} / \lambda_{k+1}$ ;
  - $err_k = |\lambda_{k+1}^{-1} - \lambda_k^{-1}|$ ;
  - 当  $err_k < \varepsilon$  时, 停止迭代;
- (5) 返回近似按模最小特征值  $\lambda_{k+1}^{-1}$  和近似特征向量  $u^{(k+1)}$ .



## §2.6 幂方法——反幂法

### 例2.4

用反幂法计算例2.1中矩阵 $A$ 的按模最小特征值及其对应的特征向量。

**解:**取初始向量 $v^{(0)} = [1.0, -0.5, 0.5]^T$ 和控制参数 $\varepsilon = 1.0 \times 10^{-4}$ .  
则 $\lambda_0 = 1$ 和 $u^{(0)} = v^{(0)}$ .

## §2.6 幂方法——反幂法

### 例2.4

用反幂法计算例2.1中矩阵 $A$ 的按模最小特征值及其对应的特征向量。

**解:**取初始向量 $v^{(0)} = [1.0, -0.5, 0.5]^T$ 和控制参数 $\varepsilon = 1.0 \times 10^{-4}$ .  
则 $\lambda_0 = 1$ 和 $u^{(0)} = v^{(0)}$ .

为避免矩阵求逆, 线性方程组 $Av^{(k+1)} = u^{(k)}$ 可以采用三角分解法求解。  
由于矩阵三角分解仅需计算一次, 所以计算量可大为减少。

$$A = \begin{bmatrix} 1.0000 & 0 & 0 \\ 0.5000 & 1.0000 & 0 \\ -0.5000 & 0.3846 & 1.0000 \end{bmatrix} \begin{bmatrix} 12.0000 & 6.0000 & -6.0000 \\ 0 & 13.0000 & 5.0000 \\ 0 & 0 & 11.0769 \end{bmatrix}$$

## §2.6 幂方法——反幂法

### 例2.4

用反幂法计算例2.1中矩阵 $A$ 的按模最小特征值及其对应的特征向量。

$k$	$v^{(k)}$	$\lambda_k^{-1}$	$u^{(k)}$
0	$[1.0, -0.5, 0.5]$	1	$[1, -0.5, 0.5]$
1	$[0.2083, -0.1250, 0.1250]$	4.8000	$[1.0000, -0.6000, 0.6000]$
2	$[0.2208, -0.1375, 0.1375]$	4.5283	$[1.0000, -0.6226, 0.6226]$
3	$[0.2237, -0.1403, 0.1403]$	4.4710	$[1.0000, -0.6274, 0.6274]$
4	$[0.2243, -0.1409, 0.1409]$	4.4591	$[1.0000, -0.6284, 0.6284]$
5	$[0.2244, -0.1411, 0.1411]$	4.4566	$[1.0000, -0.6286, 0.6286]$
6	$[0.2244, -0.1411, 0.1411]$	4.4561	$[1.0000, -0.6287, 0.6287]$
7	$[0.2244, -0.1411, 0.1411]$	4.4560	$[1.0000, -0.6287, 0.6287]$
8	$[0.2244, -0.1411, 0.1411]$	4.4560	$[1.0000, -0.6287, 0.6287]$

## §2.6 幂方法——反幂法

### 例2.4

用反幂法计算例2.1中矩阵 $A$ 的按模最小特征值及其对应的特征向量。

**解:**因此, 矩阵 $A$ 的按模最小特征值约为4.4561, 对应的特征向量约为 $[1.0000, -0.6287, 0.6287]^T$ .

## §2.7 幂方法——结合原点平移的反幂法

若已知矩阵 $A$ 的某特征值的粗略近似值 $p$ , 则可利用结合原点平移技巧的反幂法来计算该矩阵与数 $p$ 最接近的特征值及其对应的特征向量。

## §2.7 幂方法——结合原点平移的反幂法

若已知矩阵 $A$ 的某特征值的粗略近似值 $p$ , 则可利用结合原点平移技巧的反幂法来计算该矩阵与数 $p$ 最接近的特征值及其对应的特征向量。

首先作如下假设:

- (1) 数 $p$ 是矩阵 $A$ 的第 $i$ 个特征值 $\lambda_i$ 的近似, 且满足 $0 < |\lambda_i - p| < |\lambda_j - p|$ ,  $j \neq i$ .

## §2.7 幂方法——结合原点平移的反幂法

若已知矩阵 $A$ 的某特征值的粗略近似值 $p$ , 则可利用结合原点平移技巧的反幂法来计算该矩阵与数 $p$ 最接近的特征值及其对应的特征向量。

首先作如下假设:

- (1) 数 $p$ 是矩阵 $A$ 的第 $i$ 个特征值 $\lambda_i$ 的近似, 且满足 $0 < |\lambda_i - p| < |\lambda_j - p|$ ,  $j \neq i$ .

由算法假设可知:

- 矩阵 $B = A - pI$ 满足反幂法所要求的假设, 且 $\mu_i = \lambda_i - p$ 是矩阵 $B$ 的按模最小特征值。
- 对 $B$ 应用反幂法求出 $\mu_i$ 及其对应特征向量 $x^{(i)}$ 的近似值, 而矩阵 $A$ 与数 $p$ 最接近的特征值 $\lambda_i = \mu_i + p$ , 其对应的特征向量为 $x^{(i)}$ .

## §2.7 幂方法——结合原点平移的反幂法

### 算法2.4 (带原点平移的反幂法)

- (1) 给定初始非零向量  $v^{(0)}$ , 控制参数  $\varepsilon$  以及数  $p$ ;
- (2)  $\lambda_0$  为  $v^{(0)}$  中按模最大的那个分量;
- (3)  $u^{(0)} = v^{(0)} / \lambda_0$ ;;
- (4) 对  $k = 1, 2, \dots$ , 做
  - $(A - pI)v^{(k+1)} = u^{(k)}$ ;
  - $\lambda_{k+1}$  为向量  $v^{(k+1)}$  的按模最大分量;
  - $u^{(k+1)} = v^{(k+1)} / \lambda_{k+1}$ ;
  - $err_k = |\lambda_{k+1}^{-1} - \lambda_k^{-1}|$ ;
  - 当  $err_k < \varepsilon$  时, 停止迭代;
- (5) 返回近似特征值  $\lambda_{k+1}^{-1} + p$  和近似特征向量  $u^{(k+1)}$ .



## §2.7 幂方法——结合原点平移的反幂法

### 例2.5

求矩阵  $A = \begin{bmatrix} -12 & 3 & 3 \\ 3 & 1 & -2 \\ 3 & -2 & 7 \end{bmatrix}$  与数  $p = -13$  最接近的特征值及其对应的特征向量。

**解:**对矩阵  $B = A - pI$  进行LU分解, 有

$$B = \begin{bmatrix} 1 & 3 & 3 \\ 3 & 14 & -2 \\ 3 & -2 & 20 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 3 & 1 & 0 \\ 3 & -\frac{11}{5} & 1 \end{bmatrix} \begin{bmatrix} 1 & 3 & 3 \\ 0 & 5 & -11 \\ 0 & 0 & -\frac{66}{5} \end{bmatrix}.$$

取初始向量  $v^{(0)} = u^{(0)} = [1, 1, 1]^T$ , 利用结合原点平移的反幂法进行计算。

## §2.7 幂方法——结合原点平移的反幂法

### 例2.5

求矩阵  $A = \begin{bmatrix} -12 & 3 & 3 \\ 3 & 1 & -2 \\ 3 & -2 & 7 \end{bmatrix}$  与数  $p = -13$  最接近的特征值及其对应的特征向量。

$k$	$v^{(k)}$	$u^{(k)}$	$\lambda_{k+1}^{-1} + p$
0	[1, 1, 1]	[1, 1, 1]	-12
1	[-2.4545, 0.6667, 0.4848]	[1.0000, -0.2716, -0.1975]	-13.4074
2	[-4.5971, 1.0782, 0.7875]	[1.0000, -0.2345, -0.1713]	-13.2175
3	[-4.5409, 1.0676, 0.7793]	[1.0000, -0.2351, -0.1716]	-13.2202
4	[-4.5418, 1.0678, 0.7795]	[1.0000, -0.2351, -0.1716]	-13.2202

## §2.7 幂方法——结合原点平移的反幂法

### 例2.5

求矩阵  $A = \begin{bmatrix} -12 & 3 & 3 \\ 3 & 1 & -2 \\ 3 & -2 & 7 \end{bmatrix}$  与数  $p = -13$  最接近的特征值及其对应的特征向量。

**解:** 因此, 矩阵  $A$  与  $p = -13$  最接近的特征值约为  $-13.2202$ , 对应的特征向量约为  $[1.0000, -0.2351, -0.1716]^T$ .

## §3 QR方法

**QR方法**以矩阵的QR分解为基础, 是计算中小型矩阵全部特征值的最有效方法之一, 且具有收敛速度快, 算法稳定等特点。

QR方法的算法描述如下:

### 算法3.1 (QR方法)

- (1) 令  $A_1 = A$ , 并给定控制参数  $\varepsilon$ .
- (2) 对  $k = 1, 2, \dots$ , 做
  - 计算矩阵  $A_k$  的QR分解  $A_k = Q_k R_k$ ;
  - 计算  $A_{k+1} = R_k Q_k$ ;
  - $err_k = |\text{diag}(A_{k+1} - A_k)|$ ;
  - 当  $err_k < \varepsilon$  时, 停止迭代并返回  $A_{k+1}$ 。

这里  $\text{diag}(A_k)$  表示由矩阵  $A_k$  对角线元素构成的列向量。

### §3 QR方法

#### 例3.1

用QR方法计算矩阵  $A = \begin{bmatrix} 5 & -2 & -5 & -1 \\ 1 & 0 & -3 & 2 \\ 0 & 2 & 2 & -3 \\ 0 & 0 & 1 & -2 \end{bmatrix}$  的全部特征值.

解: 令  $A_1 = A$ , 利用QR分解算法对矩阵  $A_1$  进行QR分解.

$$\begin{aligned} A_1 &= Q_1 R_1 \\ &= \begin{bmatrix} 0.9806 & -0.0377 & -0.1923 & -0.1038 \\ 0.1961 & 0.1887 & -0.8804 & -0.4192 \\ 0.0000 & 0.9813 & 0.1761 & 0.0740 \\ 0.0000 & 0.0000 & 0.3962 & -0.8989 \end{bmatrix} \\ &\quad \times \begin{bmatrix} 5.0992 & -1.9612 & -5.4912 & -0.3922 \\ 0.0000 & 2.0381 & 1.5852 & -2.5288 \\ 0.0000 & 0.0000 & 2.5242 & -3.2736 \\ 0.0000 & 0.0000 & 0.0000 & 0.7822 \end{bmatrix}. \end{aligned}$$

### §3 QR方法

#### 例3.1

用QR方法计算矩阵  $A = \begin{bmatrix} 5 & -2 & -5 & -1 \\ 1 & 0 & -3 & 2 \\ 0 & 2 & 2 & -3 \\ 0 & 0 & 1 & -2 \end{bmatrix}$  的全部特征值.

解: 令  $A_2 = R_1 Q_1$ , 利用QR分解算法对矩阵  $A_2$  进行QR分解.

$$\begin{aligned} A_2 &= Q_2 R_2 \\ &= \begin{bmatrix} 0.9963 & -0.0607 & 0.0596 & 0.0142 \\ 0.0863 & 0.7011 & -0.6885 & -0.1643 \\ 0 & 0.7104 & 0.6845 & 0.1633 \\ 0 & 0 & 0.2321 & -0.9727 \end{bmatrix} \\ &\quad \times \begin{bmatrix} 4.6327 & -5.7616 & 1.2055 & 1.3985 \\ 0 & 3.4762 & -2.4634 & 3.3559 \\ 0 & 0 & 1.3093 & 0.9518 \\ 0 & 0 & 0 & 0.9486 \end{bmatrix}. \end{aligned}$$

## §3 QR方法

### 例3.1

用QR方法计算矩阵  $A = \begin{bmatrix} 5 & -2 & -5 & -1 \\ 1 & 0 & -3 & 2 \\ 0 & 2 & 2 & -3 \\ 0 & 0 & 1 & -2 \end{bmatrix}$  的全部特征值.

解:迭代20次后得到

$$A_{20} = \begin{bmatrix} 4.0000 & 0.7773 & 6.1847 & -0.8453 \\ 0.0000 & -0.4261 & -2.5937 & -3.4272 \\ 0 & 2.3263 & 2.4261 & 2.1161 \\ 0 & 0 & 0.0000 & -1.0000 \end{bmatrix}$$

### 例3.1

用QR方法计算矩阵  $A = \begin{bmatrix} 5 & -2 & -5 & -1 \\ 1 & 0 & -3 & 2 \\ 0 & 2 & 2 & -3 \\ 0 & 0 & 1 & -2 \end{bmatrix}$  的全部特征值.

解: 所以A的两个特征值为4.0000和-1.0000. 其它两个特征值满足方程

$$\begin{vmatrix} -0.4261 - \lambda & -2.5937 \\ 2.3263 & 2.4261 - \lambda \end{vmatrix} = 0,$$

即A具有两个共轭复特征值

$$\lambda \approx 1 \pm 2i.$$

事实上, 矩阵A的四个特征值分别为  $-1, 4, 1 \pm 2i$ .



## §4 Matlab简介: eig函数

对于矩阵特征值问题, Matlab软件提供了eig函数。其格式如下:

```
>> [V,D] = eig(A)
```

其中对角阵D表示矩阵A的全部特征值, 矩阵V的第*i*列为D中第*i*列对角线元素所对应的特征向量。

示例: 利用eig函数计算矩阵 $A = \begin{bmatrix} 5 & -2 & -5 & -1 \\ 1 & 0 & -3 & 2 \\ 0 & 2 & 2 & -3 \\ 0 & 0 & 1 & -2 \end{bmatrix}$ 的全部特征值及其对应的特征向量。

## §4 Matlab简介: eig函数

可在Matlab软件的命令窗口输入如下命令:

```
>> [V,D]=eig([5,-2,-5,-1;1,0,-3,2;0,2,2,-3;0,0,1,-2])
```

## §4 Matlab简介: eig函数

在命令窗口可看到计算结果:

```
>>[V,D]=eig([5,-2,-5,-1;1,0,-3,2;0,2,2,-3;0,0,1,-2])
```

V =

0.9787	0.6602	0.6602	0.5774
0.1596	0.2330 + 0.3884i	0.2330 - 0.3884i	-0.0000
0.1277	0.4272 - 0.3884i	0.4272 + 0.3884i	0.5774
0.0213	0.0388 - 0.1553i	0.0388 + 0.1553i	0.5774

D =

4.0000	0	0	0
0	1.0000 + 2.0000i	0	0
0	0	1.0000 - 2.0000i	0
0	0	0	-1.0000

```
>>
```